

VCME: Vibe Character Motion Editor

自然語言影片人物動作編輯系統

<https://github.com/B1229053/VCME-Vibe-Character-Motion-Editor>

顏羽婕、黃靖芳、洪碩廷、彭暉紘、王俊傑

指導老師：陳仁暉教授

陳仁暉

研究動機與目標

研究動機：

- 現有的影片動作修改往往需要昂貴的動態捕捉設備，且若直接編輯像素，費時且容易導致畫面扭曲

目標：

- 實現「自然語言驅動」的影片動作編輯

核心特色：

- 支持3秒內影片人物動作的修改
- 解決市面上AI修改雙人互動時，動作/光影不自然的問題
- 讓使用者能用我們的網站簡單的點選目標、輸入指令，重塑影片

VCME 系統總覽


原始瑕疵輸入影片



原始影片與
自然語言指令輸入

人物骨架提取與動作生成

SAM2
人物截取與骨架提取



SAM2影像分割與提取

接收使用者輸入的影片與自然語言指令，利用SMA2提取目標人物特徵

生成新動作的骨架




骨架動作修改

透過MDM生成大量素材以訓練其生出正常骨架

動作修復與重新渲染

修復生成的新骨架




以Animo為基底的修復模型

修復物理性的不正確與
檢查人物關節關係

ComfyUI渲染



+




結合人物特徵使用
VAE模型渲染

輸出



系統關鍵組件的功能分工

處理階段	核心技術組件	處理階段	核心技術組件
目標提取	 SAM2	動作生成	 AniMo
素材擴增	 MDM	最終合成	 ComfyUI

核心技術 1 – SAM 2 目標分離與追蹤

- **精準選取**：使用者可在畫面中點選特定人物（解決多人畫面干擾）
- **時序穩定性**：SAM2^[1] 的記憶機制確保在整段影片中，人物與背景的分離不會跳動
- **記憶機制**：SAM2 具有時序記憶，當人物在影片中旋轉、縮放甚至短暫被遮擋時，遮罩仍可以精準跟隨
- **預處理**：將分離出的人物影像轉化為基礎的3D骨架數據


[1] N. Ravi et al., "SAM 2: Segment Anything in Images and Videos," arXiv preprint arXiv:2408.00714, 2024.

精準選取與識別機制



點選式精準鎖定

透過點選機制解決多人在框時，傳統 AI 難以鎖定特定目標的技術痛點。



橘黃遮罩骨架標註

建議呈現人物被橘黃遮罩標註的對比圖，展示系統對骨架數據的識別能力。

強大的時序記憶機制



跨幀時序追蹤

具備時序記憶能力，即使目標在影片中旋轉或縮放，遮罩仍能精準跟隨。

遮擋環境抗性 (Occlusion)

當目標被短暫遮擋時，記憶機制能確保遮罩在目標重現後立即恢復精準鎖定。

核心技術 2 — MDM 與 AniMo 的結合 (主要研究目標)

- **為什麼要結合？**
 - MDM^[2]: 強大的擴散模型，能將文字轉化為流暢動作
 - AniMo^[3] 優化：引入「關節感知時空編碼」，傳統 MDM 把骨架當成 1D 向量（點的集合），AniMo 則將其視為「樹狀結構」（關節有層級關係）
 - 作法：以 AniMo 的結構作為框架，利用 MDM 生成的高質量動作數據進行微調訓練

- **技術深度對比：**

比較項目	傳統 MDM (Motion Diffusion Model)	AniMo 優化方案
核心架構	強大的擴散模型，將文字轉化為流動動作	引入「關節感知時空編碼」
數據表徵	將骨架視為 1D 向量 (純粹點的集合)	將骨架視為「樹狀結構」（具備層級關係）
物理邏輯	缺乏關節間的物理聯繫	符合人體邏輯（如：肩膀帶動手肘，手肘帶動手腕）
主要優勢	能生成流暢的初步動作	避免生成「手臂與身體斷裂」或「非人類關節旋轉」等異常動作
訓練作法	作為高品質動作數據的生成源	以 AniMo 的結構為框架，利用 MDM 生成的素材進行微調訓練（Fine-tuning）

訓練策略：使用 MDM 生成的大量動作素材來微調 AniMo，使其具備生成符合物理常理動作的能力

[2] G. Tevet, S. Raab, B. Gordon, Y. Shafir, D. Cohen-Or, and A. H. Bermano, "Human motion diffusion model," arXiv preprint arXiv:2209.14916, 2022.

[3] Wang et al., "AniMo: Species-Aware Model for Text-Driven Animal Motion Generation," CVPR, 2024.

核心技術 3 — ComfyUI^[4] 深度渲染合成

- **流程細節：**
 - 3D Mesh^[5] 生成：將編輯後的骨架轉為 3D 模型
 - 深度圖 (Depth Map)^[6] 橋接：利用深度資訊引導 AI 重繪人物細節
 - 完美合成：在 ComfyUI 中結合原背景，確保光影與邊緣與環境契合
 - 工具鏈：整合 ControlNet (Depth/Canny) 與影片生成節點
- **工作流關鍵組件：**
 - ControlNet^[7] (Canny)：提取邊緣，保留人物服裝與五官輪廓
 - ControlNet (Depth)：提取深度圖，確保修改後的動作與背景物品的距離感正確（例如：不會穿過沙發）
- **工具鏈整合：**
 - 提到整合了特定的影片生成節點（如 AnimateDiff^[8] 或相似技術），以確保幀與幀之間的穩定度

[4]R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2022, pp. 10684 - 10695.

[5]M. Loper, N. Mahmood, J. Romero, G. Pons-Moll, and M. J. Black, "SMPL: A skinned multi-person linear model," ACM Trans. Graph. (TOG), vol. 34, no. 6, pp. 1 - 16, 2015.


[6]R. Ranftl, K. Lasinger, D. Hafner, K. Schindler, and V. Koltun, "Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer," IEEE Trans. Pattern Anal. Mach. Intell. (TPAMI), vol. 44, no. 3, pp. 1623 - 1637, 2022.

[7]L. Zhang, A. Rao, and M. Agrawala, "Adding conditional control to text-to-image diffusion models," in Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 2023, pp. 3836 - 3847.

[8]Y. Guo et al., "AnimateDiff: Animate your personalized text-to-image diffusion models without specific tuning," arXiv preprint arXiv:2307.04725, 2023.

預期成果與互動編輯

- **單人編輯**：指令「讓他跳舞」、「讓他揮手」
- **進階挑戰 (雙人互動)**：系統處理兩個骨架間的距離與物理邏輯，避免穿模或動作脫節
- **網頁化願景**：展示未來網頁 UI 的初步構（選取框、文字輸入框、預覽視窗）





Thank You for
Your Attention!